Politechnika Warszawska

Wydział Elektroniki i Technik Informacyjnych

Wstęp do Sztucznej Inteligencji

ćwiczenie 2 - Algorytmy ewolucyjne i genetyczne

Autor:

Jarosław Jaworski 342189

Data oddania ćwiczenia:

1.04.2025

SPIS TREŚCI

1 Cel ćwiczenia

Celem ćwiczenia była analiza algorytmów genetycznych z rodziny algorytmów ewolucyjnych oraz zastosowanie podstawowych metod podczas realizacji przykładu. W ćwiczeniu należało rozwiązać zadanie maksymalizacji.

2 Rozwiązanie trywialne

Ćwiczenie rozpoczęto od oceny rozwiązania trywialnego. Ze względu na logikę zdobywania punktów, najprostszym sposobem na uzyskanie zadowalającego wyniku jest zaimplementowanie **szachownicy**. W tej formule, gdy naprzemiennie ustawiamy zera i jedynki, otrzymujemy dokładnie połowę pól spełniającą warunek uzyskania punktu. Oznacza to, że jeżeli posiadamy 400 pól, to połowa zapewnia punkty. Rozwiązanie to traktuje się jako odniesienie dla otrzymywanych algorytmem genetycznym. Zależność na liczbę punktów rozwiązania trywialnego opisuje wzór (1)

$$avg\_max\_points = vector\_size/2 \tag{1}$$

,zatem $avg\_max\_points = 200$.

3 Górne ograniczenie wyniku

Do znalezienia górnego maksymalnego ograniczenia wyniku potrzeba głębszej analizy istoty problemu. Porządanym efektem jest, aby każda jedynka miała w swoim otoczeniu jak największą liczbę zer. Niestety, ze względu na nieliczenie punktów "na ukos" nieodpowiednim rozwiązaniem jest stosowanie np. wypełnienia przez znak plus (z jedynką w środku i zerami w ramionach) ze względu na pozostawiane puste przestrzenie. Zagęszczenie znaku doprowadza do struktury

niemalże identycznej jak dla szachownicy. Kolejnym sposobem jest zaimplementowanie tego samego ciągu znaków w rzędzie dla całej macierzy. Minimalizacja jedynek w rzędzie przy maksymalizacji zdobytych punkt przez zera prowadzi do jednoznacznego rozwiązania maksymalnego. Wypełnienie dostępnej przestrzeni poprzez powielanie najlepszego ciągu znaków zagwarantowałoby uzyskanie maksymalnego możliwego wyniku. Implementacja wygląda następująco:

Rząd 1: 0 1 0 0 1 0 0 1 ...

Rząd 2: 0 1 0 0 1 0 0 1 ...

...

Wtedy, maksymalną liczbę punktów możemy wyznaczyć na podstawie wzoru (2)

$$max\_points = zeroes\_per\_row * rows\_num \tag{2}$$

Tym sposobem łatwo policzyć, że maksymalna liczba punktów do uzyskania na płaszczyźnie wynosi $max\_points = 260$.

4 Wyniki pomiarów

4.1 Rozwiązanie losowe - iteracja 1

Rozwiązanie losowe polegało na inicjowaniu pierwotnej populacji poprzez funkcję losową i stosowanie na niej algorytmu genetycznego. Dzięki temu zamiast zdeterminowanych wyników otrzymywano realistyczną informację o efektywności algorytmu dla różnych "punktów startowych". Testy algorytmu dla domyślnych parametrów wykonano **dla 150 różnych populacji startowych wygenerowanych losowo**. Tabela 1. przedstawia wyniki pomiarów.

Tabela 1. Wyniki pomiarów dla rozwiązania losowego

Parametr	Wartość
Średnia	216,03
Mediana	216
Odchylenie std.	2,74

Dodatkowym elementem badania algorytmu genetycznego było zbadanie przebiegu funkcji celu w zależności od iteracji. Wynik przedstawiono na Rys. 4.1.

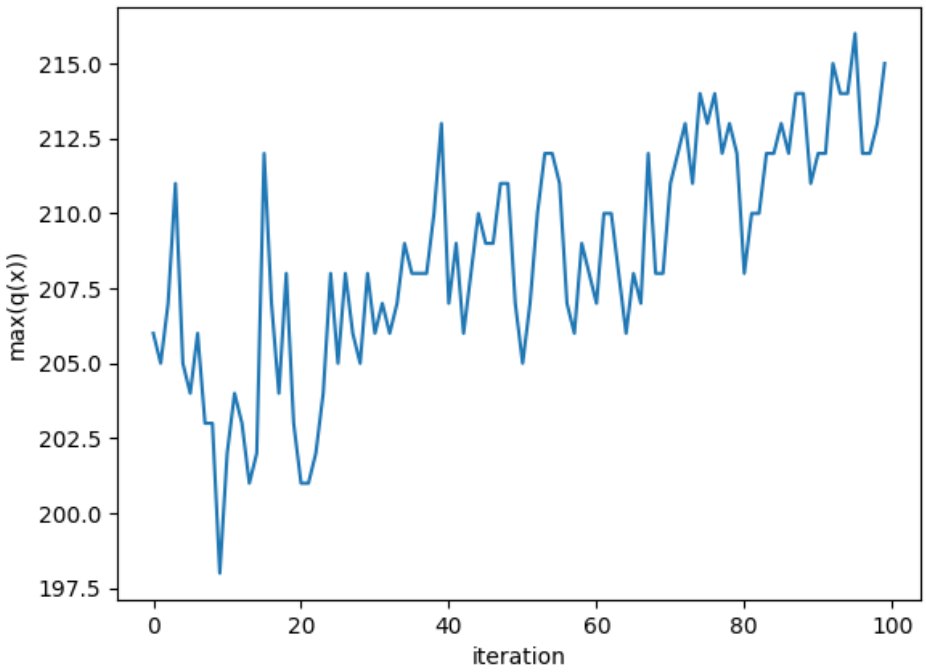

Rys. 4.1 Przebieg funkcji celu w zależności od iteracji - wizualizacja znajdowania optimum dla pojedynczego wypadku

4.2 Rozwiązanie losowe - iteracja 2 z hiperparametrami

Po zaimplementowaniu pierwszej iteracji algorytmu zauważono znaczne błędy logiczne oraz praktyczne w egzekucji programu. Problemem okazała się selekcja ruletkowa, która przebiegała z niepoprawnymi prawdopodobieństwami wyboru osobników. Z tego powodu postanowiono ponownie zaimplementować poprawioną funkcję selekcji ruletkowej z wagowym systemem losowym do oceny czy dany osobnik pozostanie wybrany. Dodatkowo zaimplementowano szansę na krzyżowanie dla osobników jako jeden z parametrów algorytmu. Na koniec założono pewne zestawy hiperparametrów w celu sprawdzenia najoptymalniejszego dla przedstawionego problemu. Algorytm działał dla populacji wielkości 500 osobników i przez 1000 generacji. Średnie wyniki przeprowadzone na przestrzeni 10 testów dla danego zestawu hiperparametrów przedstawia Tabela 2, gdzie:
M - mutation_rate, czyli szansa na zajście mutacji w genomie osobnika
C - crossover_p, czyli prawdopodobieństwo zajścia krzyżowania między osobnikami

Tabela 1. Wyniki pomiarów dla rozwiązania losowego

Zestaw hiperparametrów	**Średni wynik**
M = 0.01, C = 0.8	252
M = 0.05, C = 0.8	230
M = 0.1, C = 0.8	225
M = 0.01, C = 0.85	231
M = 0.1, C = 0.75	251.9

Przykładowy przebieg funkcji celu przedstawiono na Rys. 4.2.

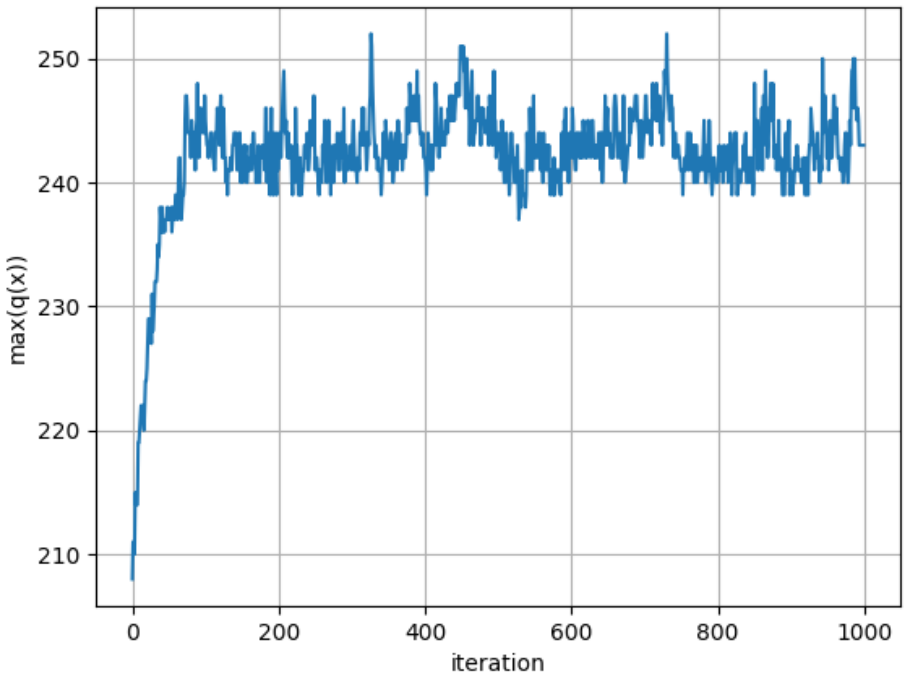

Rys. 4.2 Przebieg funkcji celu w zależności od iteracji - wizualizacja znajdowania optimum dla pojedynczego wypadku drugiej iteracji kodu

5 Wnioski

Z punktu widzenia działania algorytmu, jest to niezawodny sposób na otrzymywanie wyników **conajmniej takich jak dla rozwiązania trywialnego**. W wielu iteracjach algorytm potrafi znaleźć zadowalające rozwiązanie. Przy losowej populacji początkowej, wynik zmierza do tej samej wartości końcowej z niewielkimi odchyleniami.

Algorytm osiągał okolice najlepszego rozwiązania dla odpowiednich hiper-

parametrów i iteracji 2 kodu. Najlepszymi hiperparametrami okazały się wartości 0.01 dla szansy mutacji i 0.8 dla szany krzyżowania. Poza tym algorytm o wiele lepiej radził sobie przy większej populacji (500) oraz liczbie generacji (1000).

Algorytm genetyczny z rodziny ewolucyjnych stanowi dobre rozwiązanie dla znajdowania esktremum złożonej funkcji celu. Jego rozwiązanie jest conajmniej trywialnym, jednak nie działa on wystarczająco dobrze aby dotrzeć do optymalnego rozwiązania.

Istnieją pewne ulepszenia rozwiązania, które zaimplementowane w kodzie prawdopodobnie zbliżyły wyniki do optimum. Przykładowo - funkcja selekcji naturalnej została w ramach ćwiczenia zaimplementowana metodą ruletki. Natomiast, można tę metodę dostosować poprzez np. dodanie przeżywalności najlepszych osobników starszej generacji (elitarność).